Práctica 3.

P1: ¿Qué diferencias fundamentales existen entre un ataque de envenenamiento de datos tradicional y un ataque de tipo backdoor?
Un ataque de data poisoning lo que hace es cambiar ciertas labels, introducir imágenes incorrectas etc degradando el accruacy o rendimiento del sistema, incluyendo sesgos o cualquier tipo de comportamiento que difiere del intencionado para el sistema real, durante entrenamiento. El ataque tipo backdoor hace lo mismo, se incluyen imágenes modificadas con un trigger sutil en ellas, como un cuadrado en una señal y cuando se vea este la label se pone a otra etiqueta de toda forma que la red neuronal aprende este trigger a esa etiqueta falsa, por eso no baja el rendimiento o degrada accuracy de forma directa, no crea sesgos, sino que entrena al modelo a comportarse de forma específica con cierto tipo de input, por lo tanto ante evaluaciones de rendimiento normales no se puede detectar.

P2: Explique qué es un trigger en el contexto de los ataques de puerta trasera. ¿Qué propiedades debería tener para resultar efectivo?
El trigger es justo ese elemento que hace saltar al backdoor. Para que sea efectivo, debe ser impercetible o parecer benigno para el humano, en imageens puede ser ruido, o un pequeño cuadrado… en texto un carácter especial invisilbe, por ejemplo. Debe ser robusto ante preprocesamiento, es decir, resistir y sobrevivir transformaciones estándar que los sistemas palican a los datos antes de introducirlos por le modelo. Debe ser un patrón único, que no debe aprecer de forma natrual en el dataset limpio, porque si es algo común, como el cielo o un árbol sin hojas, el modelo podría activar este backdoor de forma constante y por accidente, revelando que existe el ataque. La presencia del trigger debe crear una señal muy fuerte en la representación latente del modelo para que domine cualquier otra activación forzando esa predicción maliciosa. La perturbación debe ser pequeña en tamaño, es decir, si estamos sobre la normla L0, alterar la menor canitdad de pixeles, si estamos sobnre la Linf , introducir variaciones muy pequeñas.

P3: ¿Qué caracteriza a los ataques clean-label poisoning? ¿Por qué resultan especialmente difíciles de detectar?
En los ataques clean-label poisoning tenemos un target, por ejemplo un perro, y una imagen base que vamos a atacar, esta imagen por ejemplo es un gato, pertenece a la clase de gatos. Lo que hacemos es hacer que la distancia entre la representación latente de la red de esa imagen del gato y la del perro disminuya, para que para el modelo sean más parecidos y cercanos, pero al mismo tiempo añadimos un regularizador para que la imagen siga pareciendo la de un gato. De esta forma obtenemos imágenes que para el modelo son perros, pero visualmente son gatosy las etiquetas ni se han tocado, entonces es muy peligroso porque al revisar seguirás viendo la imagen del gato, con su etiqueta y peudes pensar que está todo bien, sin saber que el modelo lo está viendo como un perro.

P4: En el artículo BadNets, ¿qué métricas se utilizan habitualmente para evaluar el éxito del ataque? Defina brevemente cada una de ellas.
Previamente hemos dado y visto Attack Success Rate, pero aquí van más allá:
- Clean images error rate / accuracy
  Mide rendimiento de la red ya manipulada al clasificar ndatos sin alteraciones, el modelo debería de mantener rendimiento comparable al del modelo normal sin alterar para que pase desapercibido.
- Backdoored images error rate / accuracy
  Mide la respuesta del modelo cuando se le pasan imágenes con el trigger del atacante, el ataque es exitoso si el modelo presenta un error rate bajo respecto de la etiqueta envenenada que el atacante quiere que salga con el parche.

P5: ¿Cuál es la idea principal de Neural Cleanse para detectar posibles puertas traseras en modelos de aprendizaje profundo?

No buscar en los datos, sino hacer una ingeniería inversa desde la última capa del modelo, en la que evaluamos cada cada etiqueta posible, y para cada una de estas utiliza descenso de gradiente para encontrar la perturbación más pequeña posible que al aplicarse a imágenes de otra clase diferente a esa maliciosa obligue al modelo a clasificarla como la maliciosa. Después de esto se han conseguido unos “triggers” teóricos, se miden sus magnitudes, y se usa una métrica llamada MAD (Median Absolute Deviation), que detecta valores que se desvían de la mediana (ojo no media porque la media se calcula con todos y si es un trigger super pequeño, moverá todo), entonces con este “filtro” del Median Asolute Deviation, nos quedamos con triggers con una magnitud menores a las del resto. Buscamos que dicho trigger sea de una magnitud pequeña porque normnalmente en modelos limpios par que el modelo clasifique una imagen de cierta clase con otra diferente erróneamente, debería haber un cambio grande en los píxeles, y si este trigger o parche es de tamaño pequeño y consigue hacer este cambio en la predicción de forma confiada, nos aseguramos de que el modelo presenta esta backdoor.